

# Paddy Doctor: Paddy Disease Classification – Kaggle.

Ferley José Silva Jiménez, Jonatan Jair Leal González

[ferley.silvaj@udea.edu.co](mailto:ferley.silvaj@udea.edu.co), [jonatan.leal@udea.edu.co](mailto:jonatan.leal@udea.edu.co)

*Ingeniería de Sistemas, Universidad De Antioquia, Medellín, Colombia*

## I. CONTEXTO.

El arroz (*Oryza sativa*) es uno de los cultivos más importantes a nivel mundial, constituyendo el alimento básico para más del 50% de la población global [1]. Especialmente en países de Asia, África y América Latina, su producción está estrechamente vinculada a la seguridad alimentaria y al desarrollo económico de millones de agricultores.

Sin embargo, el arroz es altamente susceptible a diversas enfermedades fúngicas y bacterianas que pueden provocar reducciones significativas en la calidad y cantidad del rendimiento agrícola [2]. Entre las enfermedades más comunes que afectan este cultivo se encuentran Bacterial Leaf Blight, Brown Spot y Leaf Smut. La identificación temprana de estas enfermedades es fundamental para evitar pérdidas económicas, pero el diagnóstico tradicional basado en la observación humana presenta limitaciones de tiempo, costos y precisión.

En este contexto, los avances en técnicas de visión por computadora y aprendizaje profundo (deep learning) han abierto nuevas oportunidades para el desarrollo de sistemas automáticos de diagnóstico fitosanitario [3]. Modelos basados en redes neuronales convolucionales (CNNs) permiten procesar imágenes de hojas de arroz afectadas para identificar de manera rápida y precisa la presencia y el tipo de enfermedad, superando las limitaciones del diagnóstico manual.

Implementar soluciones de detección automática no solo permitiría reducir costos operativos y acelerar los tiempos de respuesta, sino también incrementar la productividad agrícola y mejorar la eficiencia del uso de agroquímicos, contribuyendo así a una agricultura más sostenible y rentable [4]. Además, estas herramientas pueden integrarse fácilmente en aplicaciones móviles accesibles para pequeños agricultores, democratizando el acceso a tecnologías de diagnóstico avanzadas.

## II. OBJETIVO DE MACHINE LEARNING.

El objetivo de este proyecto es desarrollar un modelo de aprendizaje profundo (deep learning) capaz de clasificar automáticamente imágenes de hojas de plantas de arroz según su estado de salud o el tipo de enfermedad que presenten.

Queremos predecir, a partir de una imagen digital de una hoja de arroz, si la planta está sana o si sufre de alguna de las siguientes enfermedades:

- Bacterial leaf blight
- Brown spot
- Hispa
- Tungro
- Healthy (hoja sin síntomas visibles)

El modelo tendrá como entrada imágenes en formato digital y deberá aprender a reconocer patrones visuales

relevantes (como cambios en la textura, la presencia de manchas, decoloraciones o deformaciones) que permitan una clasificación precisa de las hojas.

Se utilizarán redes neuronales convolucionales (CNN) como base tecnológica, aprovechando su capacidad para extraer automáticamente características discriminantes de las imágenes, sin necesidad de diseñar manualmente atributos específicos.

La capacidad de identificar tanto múltiples enfermedades como el estado sano de las hojas permitirá construir un sistema de diagnóstico agrícola ágil, escalable y preciso, orientado a facilitar la detección temprana de problemas fitosanitarios en los cultivos de arroz.

### III. DESCRIPCIÓN DE LOS DATOS.

El conjunto de datos está conformado por un total de 13.876 imágenes de hojas de arroz, con un tamaño aproximado de 1.09 GB. De estas, 10.407 imágenes están etiquetadas y distribuidas en diez clases: nueve correspondientes a diferentes enfermedades y una a hojas sanas. Además, cada imagen etiquetada cuenta con metadatos adicionales, como la variedad del arroz y su edad. Las 3.469 imágenes restantes no están etiquetadas y se destinan al proceso de evaluación del modelo. La distribución de muestras se ve en la Fig 1.




Fig 1. Distribución de muestras por clase en datos de entrenamiento

### IV. MÉTRICAS DE DESEMPEÑO.

Para evaluar el rendimiento técnico del modelo de clasificación de imágenes se utilizarán las siguientes métricas:

#### ***Accuracy (Precisión general).***

Medida principal que indica el porcentaje de predicciones correctas sobre el total de muestras evaluadas. Es especialmente útil dado que las clases en el dataset están relativamente balanceadas.

#### ***Matriz de confusión.***

Permite analizar en detalle los errores de clasificación, observando para cada clase cuántas predicciones fueron correctas y cuántas fueron confundidas con otras clases.

### ***Categorical Cross-Entropy Loss.***

Función de pérdida utilizada para la optimización del modelo durante el entrenamiento. Un valor de pérdida bajo indicará que el modelo está realizando predicciones más cercanas a las etiquetas reales.

## **V. RESULTADOS PREVIOS.**

### ***Resultados Previos en el Reconocimiento de Enfermedades en Arroz Mediante Redes Convolucionales.***

La detección de enfermedades en cultivos de arroz ha evolucionado considerablemente gracias a la aplicación de redes neuronales convolucionales (CNN). En un estudio reciente, Ning et al. [2] analizaron distintos modelos CNN enfocándose no solo en la precisión del reconocimiento, sino también en la velocidad de inferencia y el peso computacional de los modelos, aspectos esenciales para su uso en dispositivos móviles o entornos agrícolas de recursos limitados.

El estudio evaluó múltiples arquitecturas, incluyendo redes profundas y versiones ligeras como MobileNet, EfficientNet y ShuffleNet, comparándolas con modelos tradicionales más pesados. Se encontró que, aunque los modelos de gran tamaño alcanzan mejores tasas de precisión, los modelos ligeros ofrecen un balance mucho más adecuado para aplicaciones en tiempo real, donde la eficiencia energética y la rapidez son prioritarias.

Además, el trabajo destacó que mediante técnicas de optimización, como la reducción de parámetros y la implementación de estrategias de comprensión de modelos, es posible mantener un alto rendimiento en la clasificación de enfermedades comunes del arroz, como el tizón de la hoja o la mancha marrón, sin sacrificar notablemente la precisión.

Estos resultados subrayan la importancia de considerar tanto el rendimiento como la eficiencia de los modelos de aprendizaje profundo para su implementación práctica en el monitoreo agrícola, lo que marca una base sólida para investigaciones futuras en el área de agricultura inteligente.

## **VI. REFERENCIAS**

- [1] F. Muthayya, J. Sugimoto, S. Montgomery, and G. Maberly, "An overview of global rice production, supply, trade, and consumption," *Annals of the New York Academy of Sciences*, vol. 1324, no. 1, pp. 7–14, 2014.
- [2] H. Ning, S. Liu, Q. Zhu, and T. Zhou, "Convolutional neural network in rice disease recognition: accuracy, speed and lightweight," *Frontiers in Plant Science*, vol. 14, p. 1269371, 2023. [Online]. Available: <https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2023.1269371/full>
- [3] K. Kamilaris and F. X. Prenafeta-Boldú, "Deep learning in agriculture: A survey," *Computers and Electronics in Agriculture*, vol. 147, pp. 70–90, Apr. 2018.
- [4] R. Sladojevic, M. Arsenovic, A. Anderla, D. Culibrk, and D. Stefanovic, "Deep Neural Networks Based Recognition of Plant Diseases by Leaf Image Classification," *Computational Intelligence and Neuroscience*, vol. 2016, Article ID 3289801, 2016.
- [5] Paddy Doctor, Pandarasamy Arjunan (Samy), and Petchiammal. Paddy Doctor: Paddy Disease Classification. <https://kaggle.com/competitions/paddy-disease-classification>, 2022. Kaggle.